Universidade Federal de Santa Maria
Centro de Ciências Naturais e Exatas
Departamento de Estatística
Especialização em Estatística e Modelagem Quantitativos
Séries Temporais

Seja breve e sucinto em suas respostas!

NOME: Desirée Prati Ribeiro DATA: 17/10/2024

1. Em sua opinião qual a diferença fundamental de séries temporais e modelos de regressão:
Em séries temporais, os dados são dependentes do tempo, enquanto em modelos de regressão clássica, as variáveis são independentes entre si.

2. O que é sazonalidade e ciclo. Diferencie estas duas componentes de uma série temporal:
Sazonalidade refere-se a padrões regulares e repetitivos que ocorrem dentro de intervalos fixos (como anual), enquanto o ciclo se refere a flutuações de longo prazo que não têm periodicidade fixa.

3. Diferencie um modelo simples de um modelo sazonal:
Um modelo simples não considera variações sazonais, enquanto um modelo sazonal inclui termos que capturam padrões repetitivos em intervalos regulares.

4. O que é a metodologia Box & Jenkins?
Refere-se ao processo de modelagem de séries temporais por meio de modelos ARIMA, que incluem identificação, estimação e verificação do modelo.

5. Explique o que é um modelo ARIMA (1, 1, 2).
Um modelo ARIMA(1, 1, 2) tem 1 termo autorregressivo (AR), 1 diferenciação para tornar a série estacionária, e 2 termos de médias móveis (MA) para modelar os erros passados.

6. Como podemos verificar se um modelo encontrado pela metodologia B&J é melhor do que outro? Que tipos de critérios podemos utilizar?
Usam-se critérios como AIC, BIC e a análise dos resíduos para determinar a qualidade do ajuste de um modelo em relação a outro.

7. Para que serve um correlograma e um correlograma parcial?
Um correlograma serve para visualizar a autocorrelação de uma série temporal em diferentes lags, enquanto um correlograma parcial mostra a autocorrelação ajustada para os lags intermediários, ajudando a identificar a estrutura do modelo.

8. Como fica graficamente o correlograma e o correlograma parcial, quando se tem um modelo AR e um MA?
Em um modelo AR, o correlograma mostra um decaimento lento da autocorrelação, indicando que a autocorrelação persiste por muitos lags e o parcial apresenta um corte abrupto após o primeiro lag, indicando que apenas o primeiro lag é significativo.

No modelo MA, o correlograma exibe um corte abrupto na autocorrelação após um número específico de lags, normalmente igual ao grau do modelo MA. E o parcial mostra um decaimento lento, indicando que a autocorrelação residual persiste em lags subsequentes.

9. Escreva o modelo AR(1) genérico;
$X_t=\phi X_{t-1}+\epsilon_t$

X_t é o valor da série no tempo t,
ϕ é o coeficiente autorregressivo,
ϵ_t é o termo de erro (ruído branco).

10. Escreva o modelo MA (1) genérico;
$X_t=\mu+\epsilon_t+\theta\epsilon_{t-1}$

X_t é o valor da série no tempo t,
μ é a média,
ϵ_t é o erro no tempo ttt (ruído branco),
θ é o coeficiente de médias móveis,
ϵ_{t-1} é o erro no tempo anterior.

11. O que são e para que servem as condições de estacionariedade e inversibilidade no AR e no MA?
A estacionariedade garante que as propriedades da série sejam constantes ao longo do tempo, enquanto a inversibilidade evita ambiguidades na estimativa dos parâmetros.

12. As transformações em utilizadas em ST são úteis para que finalidade?
São úteis para estabilizar a variância (como logaritmos) ou para tornar a série estacionária (como a diferenciação).

13. Se você fosse realizar uma análise de ST, o que você observaria em primeiro lugar?
Verificar a estacionariedade da série, porque a estacionariedade é fundamental para a maioria dos métodos de análise de séries temporais, como ARIMA. Modelos de séries estacionárias têm propriedades constantes ao longo do tempo, o que facilita a previsão e a interpretação dos resultados.

14. Realize a primeira diferença e a segunda diferença até o décimo lag.

```
# Dados fornecidos
Zt <- c(0.466, 0.069, 1.158, 0.187, 0.483, 0.92, 0.754, 0.218, 0.81, 1.25,
        0.949, 0.913, 0.705, 1.009, 0.147, 1.336, -0.793, -0.484, -1.932,
        -1.333, -0.752, 0.092, -0.562, 1.521, 1.336, 0.904, 1.836, -0.259,
        1.876, 3.688, 1.988, 2.241, 2.993, 3.515, 3.185, 4.37, 1.929, 0.874,
        1.556, 0.267, 1.496, -0.207, 2.265, 2.819, 3.425, 1.072, 1.15, 1.34,
        -0.047, 1.1)

# Primeira diferença
primeira_dif <- diff(Zt, differences = 1)

# Segunda diferença
```

segunda_dif <- diff(Zt, differences = 2)

 # Exibir até o décimo lag
primeira_dif[1:10]
```
[1] -0.397  1.089 -0.971  0.296  0.437 -0.166 -0.536  0.592  0.440 -0.
301
```
segunda_dif[1:10]
```
[1]  1.486 -2.060  1.267  0.141 -0.603 -0.370  1.128 -0.152 -0.741  0.
265
```

15. Do banco de dados fornecido calcule as funções de autocorrelações e autocorrelações parciais, e trace os respectivos gráficos até o terceiro lag.
 # Dados fornecidos
```
Zt <- c(0.466, 0.069, 1.158, 0.187, 0.483, 0.92, 0.754, 0.218, 0.81, 1.25,
        0.949, 0.913, 0.705, 1.009, 0.147, 1.336, -0.793, -0.484, -1.932,
        -1.333, -0.752, 0.092, -0.562, 1.521, 1.336, 0.904, 1.836, -0.259,
        1.876, 3.688, 1.988, 2.241, 2.993, 3.515, 3.185, 4.37, 1.929, 0.874,
        1.556, 0.267, 1.496, -0.207, 2.265, 2.819, 3.425, 1.072, 1.15, 1.34,
        -0.047, 1.1)
```

 # Carregar a biblioteca forecast para funções ACF e PACF
library(forecast)

 # Calcular e plotar a função de autocorrelação (ACF) até o 3º lag
acf(Zt, lag.max = 3, main = "Autocorrelação até o 3º Lag")

 # Calcular e plotar a função de autocorrelação parcial (PACF) até o 3º lag
pacf(Zt, lag.max = 3, main = "Autocorrelação Parcial até o 3º Lag")

Autocorrelação até o 3º Lag

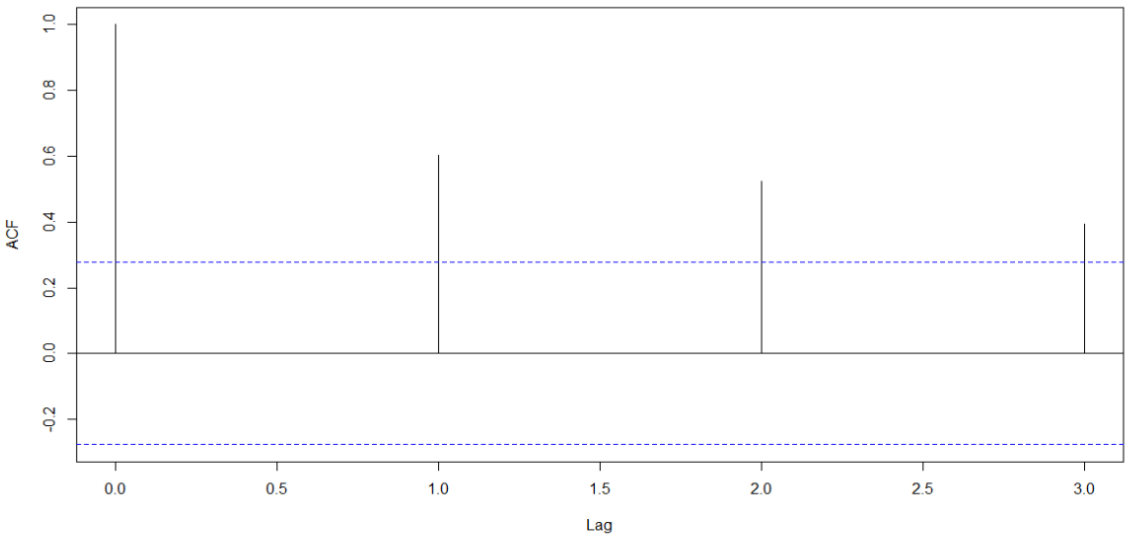

Autocorrelação Parcial até o 3º Lag